

Relatório de EDA: voos internacionais saindo do Brasil

Projeto de Inovação: Boost Your English

O que a base da ANAC permite e o que ela não permite afirmar sobre a sazonalidade das viagens a países de língua inglesa, como insumo para o calendário de captação de uma escola de inglês online.

Grupo 4

Entregáveis: EDA_Grupo4_Notebook.ipynb • EDA_Grupo4_Relatorio.pdf • EDA_Grupo4_Dicionario.xlsx

Base: ANAC, Dados Estatísticos do Transporte Aéreo (etapas combinadas), jan/2025 a jul/2026 • Outubro de 2026

Como ler este relatório

A base analisada tem 214.882 linhas: todos os registros da ANAC com origem no Brasil e destino no exterior, de janeiro de 2025 a julho de 2026. O **recorte do projeto** são os voos para Estados Unidos, Canadá e Reino Unido. Os demais destinos não foram descartados: eles formam o **grupo de comparação**, que permite separar o que é sazonalidade de viagem internacional em geral do que é próprio dos destinos de língua inglesa.

Todo número citado sai do notebook EDA_Grupo4_Notebook.ipynb, e cada figura indica a seção de onde foi tirada. As células acrescentadas pelo grupo estão marcadas com [Grupo 4]; o resto do notebook é o roteiro da disciplina, alterado só na célula de configuração.

Procurado × encontrado por acaso. Os achados levam uma etiqueta. **procurado** indica que fomos atrás deles de propósito, porque respondem à pergunta de negócio. **por acaso** indica que apareceram no caminho, sem que tivéssemos ido procurar. Achado por acaso é relatado como hipótese, não como conclusão.

Índice sazonal. Para comparar grupos de tamanhos muito diferentes (o recorte tem cerca de 230 mil passageiros por mês; os não anglófonos, cerca de 1 milhão), usamos o mês dividido pela média de março a junho do mesmo ano, vezes 100. Março a junho é período letivo e fica longe do Carnaval. Índice 124 significa 24% acima do período letivo.

1. Pergunta de negócio

A escola Boost Your English quer saber se viagens a países de língua inglesa marcam épocas de maior procura por aulas, para planejar campanhas e abertura de turmas. A pergunta geral se desdobra em quatro, no formato da Aula 5:

Pergunta central: em que meses o fluxo de passageiros do Brasil para EUA, Canadá e Reino Unido sobe acima do período letivo, esse pico é próprio dos destinos de língua inglesa (e não das férias em geral), e ele antecede a procura por aulas na escola?

	Métrica	Recorte	Comparação	Decisão que habilita
P1. Quando o fluxo para o recorte sobe, e quanto?	Passageiros (pagos + grátis) por mês em voos de passageiros; índice sazonal	Origem Brasil, destino EUA/Canadá/Reino Unido, jan/2025 a jul/2026, sem cargueiros	Cada mês contra mar–jun do mesmo ano; 2025 contra 2026	Janelas do calendário de captação: em quais meses concentrar campanha de inglês para viagem
P2. O pico é dos destinos de língua inglesa ou das férias em geral?	Índice sazonal por grupo; variação de julho sobre junho	Todos os destinos internacionais, em recorte × não anglófonos, e por continente	Recorte contra grupo de comparação, dentro de cada continente	Se o pico for igual, a viagem não é sinal próprio e a escola usa o calendário de férias genérico; se for diferente, a série do recorte vale como variável no cruzamento com a base do cliente
P3. O pico vem de mais voos ou de voos mais cheios?	Voos de passageiros por mês e passageiros por voo (índices); passageiros por voo nas férias e fora delas	Recorte, na unidade voo	Meses de pico contra período letivo; férias contra fora das férias, por grupo de destino	Se for oferta (mais voos), a malha que as companhias publicam com meses de antecedência serve de indicador antecipado para a escola
P4. A procura por aulas antecede o pico de viagens? (parcial)	Correlação entre cadastros de alunos e passageiros do recorte, com defasagem de 0 a 6 meses	Alunos do cliente × série do recorte	Defasagens; série sem o componente sazonal comum	Antecedência das campanhas e da abertura de turmas. Depende da base do cliente: esta EDA prepara o lado das viagens

2. Matriz: pergunta → métrica → colunas → operação

Pergunta	Métrica	Colunas	Operação	Na base?
P1	Passageiros por mês; índice sazonal	nr_passag_pagos, nr_passag_gratis, dh_partida_real, grupo_destino, ds_servico_tipo_linha	Filtrar recorte e voos de passageiros; somar passageiros por voo e por mês; dividir pela média de mar-jun do ano	Sim
P2	Índice sazonal por grupo; jul/jun	+ nm_pais_destino, nm_continente_destino	Tabela dinâmica mês × grupo; mesmo índice em cada grupo; facetas por grupo; abertura por continente e país	Sim
P3	Voos por mês; passageiros por voo	sg_empresa_icao, nr_voo, dh_partida_real (chave do voo) + passageiros	Agrupar linhas no voo; contar voos e somar passageiros por mês; teste de Simpson férias × fora por grupo de destino; IC por bootstrap	Sim
P4	Correlação com defasagem	Série mensal do recorte + data de cadastro do aluno (cliente)	Agregar cadastros por mês ou semana; juntar com a série por período; correlação cruzada com defasagens	Parcial: requer dados do cliente
Qualidade	% de nulos; repetições do grão; nulos disfarçados	ds_cotran, ds_tipo_empresa, ds_servico_tipo_linha, chave do grão	Contar nulos; comparar linhas com e sem o valor; contar repetições na chave	Sim

3. Relatório de nulos

3.1 Ausência por coluna

Só 8 das 27 colunas têm ausência explícita. As outras 19 estão 100% preenchidas.

Coluna	Nulos	% das linhas	Observação
ds_cotran	100.087	46,6%	Tipo de movimento (desembarque ou conexão)
nr_passag_pagos	68	0,03%	Mesmas 68 linhas em todas as medidas
nr_passag_gratis	68	0,03%	idem
kg_bagagem_livre	68	0,03%	idem
kg_carga_paga	68	0,03%	idem
kg_bagagem_excesso	68	0,03%	idem
kg_carga_gratis	68	0,03%	idem
kg_correio	68	0,03%	idem
Demais 19 colunas	0	0%	

3.2 Nulos disfarçados

A busca automática por textos suspeitos ("-", "n/a", "não informado" etc.) não achou nada. A inspeção manual achou um nulo disfarçado de categoria e descartou os outros candidatos:

Candidato	Linhas	Veredito
ds_servico_tipo_linha = NÃO IDENTIFICADO	100.087 (46,6%)	Nulo disfarçado. São exatamente as mesmas linhas em que ds_cotran é nulo: o campo não foi informado. Fica como categoria, e não em NA_EXTRA, porque marca o regime de declaração (ver 3.3).
Zero em nr_passag_pagos	67.462 (31,4%)	Não é ausência. Os zeros vêm de cargueiros (7.365 linhas, todas zero), de voos improdutivos (1.453, todas zero) e das linhas de conexão doméstica (97% zero). Zero é valor legítimo nessas subpopulações.
Zero nas colunas kg_	66% a 97%	Não é ausência: voo de passageiro sem carga, sem correio ou sem excesso de bagagem tem peso zero de fato.
Hora de partida 00:00	235 (0,1%)	Suspeita leve (1,6 vez a média por minuto do dia). Não muda nenhuma métrica mensal; mantido e anotado.

3.3 Hipóteses sobre o padrão de ausência, com evidência

H-N1. ds_cotran falta por causa da nacionalidade da empresa (ausência estrutural, explicada por outra coluna)

por acaso

Evidência	O que mostra
Comparação com e sem valor	ds_cotran é nulo em 100% das linhas de empresas estrangeiras (100.087) e em 0% das brasileiras (114.795). A separação é perfeita.
Mapa de ausência	As linhas nulas estão espalhadas pela base inteira, e não em blocos. Não há faixa contínua que indique falha de carga num período.
Taxa por mês	A taxa mensal fica entre 43% e 51% nos 19 meses: a ausência acompanha a participação das estrangeiras, não o calendário.
Correlação entre nulos	Correlação de 0,02 entre a ausência de ds_cotran e a das medidas: são duas origens diferentes.




Figura 1. % de linhas sem ds_cotran por origem da empresa (esq.) e por mês de partida (dir.). Notebook, seção 2.4.

Leitura: as estrangeiras declaram à ANAC num formato que não detalha o tipo de movimento, e o par de aeroportos vem numa linha só. Nas brasileiras o mesmo par vem em até três linhas. Não faz sentido imputar: o valor não existe na origem. Consequência para a análise: 68,1% dos passageiros pagos não podem ser separados entre quem desembarca e quem segue em conexão.

H-N2. As 68 linhas sem nenhuma medida são declarações incompletas de estrangeiras, ainda não revisadas

por acaso

Perfil	Com medida	Sem medida
Empresa estrangeira	46,6%	100%
ds_grupo_di = IMPRODUTIVO	0,7%	35,3%
ds_grupo_di = NÃO REGULAR	6,5%	19,1%
Partida em mai-jul/2026	15,5%	38,2%

As sete medidas faltam sempre juntas (correlação 1,00 entre elas, Figura 2): é a linha inteira que veio sem números, e não um campo que falhou. Nenhuma linha fora desse grupo tem nulo numérico. 26 das 68 estão nos três últimos meses.



Figura 2. Correlação entre as ausências. Notebook, seção 2.1.

Imputação: nenhuma ausência foi imputada (ver decisões na seção 7), então não há distribuição antes e depois a comparar.

Como verificar: baixar de novo os arquivos de mai-jul/2026 depois da revisão da ANAC e ver se as linhas ganham valores. Como são 0,03% da base, a decisão de removê-las não muda nenhum resultado.

4. Dicionário de dados

A versão completa está em EDA_Grupo4_Dicionario.xlsx, com três abas: granularidade, dicionário por campo e campos derivados da tabela por voo. Abaixo, a granularidade e as cinco dimensões de cada campo (significado, tipo, domínio, nulidade, origem). Variáveis derivadas trazem a fórmula que as gerou na coluna Origem. No xlsx, uma sétima coluna registra a decisão de tratamento de cada campo, resumida na seção 7.

Item	Descrição
Arquivo	data/base_eda_internacional.csv (Latin-1, separador ';', 214.882 linhas x 27 colunas)
Fonte	ANAC, Dados Estatísticos do Transporte Aéreo, variante de etapas combinadas, arquivos mensais combinadaAAAA-MM
Cobertura temporal	Arquivos de jan/2025 a jul/2026 (19 meses). Partidas de 31/12/2024 23:47 a 01/08/2026 22:29: 2 linhas caem em dez/2024 e 22 em ago/2026, fora dos meses completos
Recorte de linhas	nm_pais_origem = BRASIL e nm_pais_destino diferente de BRASIL (3.709.917 linhas lidas, 214.882 mantidas). Gerado por scripts/filter_eda.py
Grão (o que é uma linha)	Um par de aeroportos (embarque no Brasil x desembarque no exterior) dentro de um voo. Nas empresas brasileiras o par é desdobrado em até 3 linhas pelo tipo de movimento (ds_cotran: desembarque, conexão internacional, conexão doméstica); nas estrangeiras vem em uma linha só
Chave do grão	sg_empresa_icao + nr_voo + dh_partida_real + sg_icao_origem + sg_icao_destino + nr_escala_destino + ds_cotran. Única exceto por 6 voos declarados em dois arquivos mensais (duplicatas reais, ver relatório de nulos e qualidade)
Chave técnica	id_combinada, única em todas as 214.882 linhas
Unidade de análise	O voo: sg_empresa_icao + nr_voo + data de partida. 214.882 linhas viram 130.513 voos (1,65 linha por voo); 120.410 são voos de passageiros (excluídos cargueiros e voos sem passageiro)
Grupos de destino	RECORTE = EUA, Canadá, Reino Unido (36.412 linhas). OUTRO ANGLÓFONO = África do Sul e 16 países menores (1.448). NÃO ANGLÓFONO = demais 54 países (177.022), grupo de comparação

Campo	Significado	Tipo	Domínio	Nulidade	Origem
id_combinada	Identificador do registro na base combinada da ANAC.	Inteiro (identificador, não é medida)	93.056.876 a 107.982.976; 214.882 valores distintos (único por linha).	Não aceita nulo. 0% nulo.	ANAC, coluna id_combinada.
sg_empresa_icao	Sigla ICAO de três letras da empresa aérea que operou o voo.	Texto, categórico nominal (3 caracteres)	114 siglas; TAM (LATAM Brasil) é a mais frequente, com 26,8% das linhas.	Não aceita nulo. 0% nulo.	ANAC, coluna sg_empresa_icao.
nr_voo	Número do voo atribuído pela empresa. Junto com a empresa e a data, identifica o voo.	Texto (código; lido como texto para preservar zeros à esquerda, ex.: 0271)	1.922 números distintos, de 0 a 9992.	Não aceita nulo. 0% nulo.	ANAC, coluna nr_voo.
dh_partida_real	Data e hora em que o voo efetivamente decolou do aeroporto de origem.	Data e hora (DD/MM/AAAA HH:MM:SS)	31/12/2024 23:47 a 01/08/2026 22:29. Meses completos: jan/2025 a jul/2026.	Não aceita nulo. 0% nulo.	Derivada (filter_eda.py). Fórmula: dt_partida_real convertida para DD/MM/AAAA + ' ' + hr_partida_real.
sg_icao_origem	Código ICAO do aeroporto brasileiro de embarque.	Texto, categórico nominal	32 aeroportos; SBGR (Guarulhos) concentra 53,4% das linhas e 57,0% dos passageiros pagos.	Não aceita nulo. 0% nulo.	ANAC, coluna sg_icao_origem.
sg_icao_destino	Código ICAO do aeroporto de desembarque no exterior.	Texto, categórico nominal	195 aeroportos; SABE (Buenos Aires, Aeroparque) é o mais frequente (15,0%).	Não aceita nulo. 0% nulo.	ANAC, coluna sg_icao_destino.
ds_cotran	Tipo de movimento dos passageiros no par de aeroportos: desembarque no destino, conexão para voo internacional ou conexão para voo doméstico.	Texto, categórico nominal	DESEMBARQUE, CONEXÃO INTERNACIONAL, CONEXÃO DOMÉSTICO.	Aceita nulo. 46,6% nulo (100.087 linhas). Ausência estrutural: 100% nula nas empresas estrangeiras e 0% nas brasileiras.	ANAC, coluna ds_cotran.

Campo	Significado	Tipo	Domínio	Nulidade	Origem
nr_etapa	Ordem da etapa dentro do voo (1 = primeira decolagem).	Inteiro, ordinal	1 a 7; 91,0% das linhas são etapa 1.	Não aceita nulo. 0% nulo.	ANAC, coluna nr_etapa.
nr_escala_destino	Posição do aeroporto de destino na sequência de pousos do voo (2 = primeiro pouso após a origem).	Inteiro, ordinal	2 a 9; 85,7% das linhas são 2.	Não aceita nulo. 0% nulo.	ANAC, coluna nr_escala_destino.
nr_passag_pagos	Passageiros pagantes embarcados naquele par de aeroportos. Métrica principal da análise.	Inteiro, contagem (lido como decimal)	0 a 484. 31,4% das linhas são zero (cargueiros, conexão doméstica, improdutivos). Distribuição com três modas: 0, cerca de 150 e cerca de 270.	Aceita nulo. 0,03% nulo (68 linhas, as mesmas de todas as medidas, todas de empresas estrangeiras).	ANAC, coluna nr_passag_pagos.
nr_passag_gratis	Passageiros embarcados sem pagar tarifa naquele par de aeroportos.	Inteiro, contagem (lido como decimal)	0 a 260; 71,4% zero. O máximo (260 gráts com 9 pagos, Delta, 23/05/2025) é suspeito.	Aceita nulo. 0,03% nulo (as mesmas 68 linhas).	ANAC, coluna nr_passag_gratis.
kg_bagagem_livre	Peso da bagagem despachada dentro da franquia, em quilos.	Decimal, quilos	0 a 9.343; 72,0% zero.	Aceita nulo. 0,03% nulo (as mesmas 68 linhas).	ANAC, coluna kg_bagagem_livre.
kg_carga_paga	Peso da carga paga transportada, em quilos.	Decimal, quilos	0 a 126.977; 66,5% zero. Valores altos vêm de cargueiros.	Aceita nulo. 0,03% nulo (as mesmas 68 linhas).	ANAC, coluna kg_carga_paga.
kg_bagagem_excesso	Peso da bagagem cobrada como excesso, em quilos.	Decimal, quilos	0 a 1.279; 96,4% zero.	Aceita nulo. 0,03% nulo (as mesmas 68 linhas).	ANAC, coluna kg_bagagem_excesso.
kg_carga_gratis	Peso da carga transportada sem cobrança, em quilos.	Decimal, quilos	Deveria ser maior ou igual a 0. Observado de -33 a 43.554; 3 negativos (Azul) são erro. 95,8% zero.	Aceita nulo. 0,03% nulo (as mesmas 68 linhas).	ANAC, coluna kg_carga_gratis.
kg_correio	Peso das malas postais transportadas, em quilos.	Decimal, quilos	0 a 8.079; 97,1% zero.	Aceita nulo. 0,03% nulo (as mesmas 68 linhas).	ANAC, coluna kg_correio.
nm_empresa	Razão social da empresa aérea.	Texto, categórico nominal	114 empresas (1 para 1 com sg_empresa_icao).	Não aceita nulo. 0% nulo.	ANAC, coluna nm_empresa.
nm_pais_empresa	País de nacionalidade da empresa aérea.	Texto, categórico nominal	46 países; BRASIL em 53,4% das linhas. BRASIL coincide exatamente com os tipos de empresa nacionais.	Não aceita nulo. 0% nulo.	ANAC, coluna nm_pais (renomeada para não confundir com o país de origem do voo).
ds_tipo_empresa	Tipo de autorização da empresa: nacional ou estrangeira, regular ou não regular.	Texto, categórico nominal	ESTRANGEIRA REGULAR (46,2%), TRANSPORTE AÉREO REGULAR (26,8%), TRANSPORTE AÉREO NÃO REGULAR, TRANSPORTE AÉREO REGULAR (26,6%), ESTRANGEIRA NÃO REGULAR (826 linhas), TRANSPORTE AÉREO NÃO REGULAR (33 linhas).	Não aceita nulo. 0% nulo.	ANAC, coluna ds_tipo_empresa.
ds_grupo_di	Natureza da operação segundo o dígito identificador do voo: regular, não regular (fretamento, extra) ou improdutivo (sem receita, como traslado de aeronave).	Texto, categórico nominal	REGULAR (92,8%), NÃO REGULAR (6,5%), IMPRODUTIVO (0,7%; sempre zero passageiro).	Não aceita nulo. 0% nulo.	ANAC, coluna ds_grupo_di.
ds_servico_tipo_linha	Tipo de serviço da linha: passageiros ou carga.	Texto, categórico nominal	PASSAGEIRO (50,0%), NÃO IDENTIFICADO (46,6%), CARGUEIRO (3,4%).	Não tem nulo explícito, mas NÃO IDENTIFICADO é nulo disfarçado: coincide com as 100.087 linhas de empresas estrangeiras. Mantido como categoria.	ANAC, coluna ds_servico_tipo_linha.
nm_municipio_origem	Município do aeroporto de embarque.	Texto, categórico nominal	32 municípios; Guarulhos 53,4%, Rio de Janeiro 16,4%.	Não aceita nulo. 0% nulo.	ANAC, coluna nm_municipio_origem.
sg_uf_origem	Unidade da federação do aeroporto de embarque.	Texto, categórico nominal (2 caracteres)	23 UFs; SP 61,3%, RJ 16,5%.	Não aceita nulo. 0% nulo.	ANAC, coluna sg_uf_origem.
nm_municipio_destino	Município do aeroporto de desembarque no exterior.	Texto, categórico nominal	191 municípios; Buenos Aires 15,0% das linhas.	Não aceita nulo. 0% nulo.	ANAC, coluna nm_municipio_destino.

Campo	Significado	Tipo	Domínio	Nulidade	Origem
nm_pais_destino	País do aeroporto de desembarque.	Texto, categórico nominal	74 países; Argentina 26,2%, EUA 15,1%, Chile 12,0%. A grafia é ESTADOS UNIDOS DA AMÉRICA e REINO UNIDO.	Não aceita nulo. 0% nulo.	ANAC, coluna nm_pais_destino.
nm_continente_destino	Continente do aeroporto de desembarque.	Texto, categórico nominal	AMÉRICA DO SUL (57,1%), EUROPA, AMÉRICA DO NORTE, AMÉRICA CENTRAL, ÁFRICA, ÁSIA, OCEANIA (1 linha).	Não aceita nulo. 0% nulo.	ANAC, coluna nm_continente_destino
grupo_destino	Classificação do destino para a pergunta de negócio: recorte do projeto, outro país de língua inglesa ou grupo de comparação.	Texto, categórico nominal	RECORTE (EUA, Canadá, Reino Unido; 16,9% das linhas), NÃO ANGLÓFONO (82,4%), OUTRO ANGLÓFONO (0,7%).	Não aceita nulo. 0% nulo.	Derivada (filter_eda.py). Fórmula: RECORTE se nm_pais_destino em {EUA, Canadá, Reino Unido}; OUTRO ANGLÓFONO se em lista de 20 países de língua oficial inglesa; senão NÃO ANGLÓFONO.

5. Análise exploratória

5.1 Estrutura e grão

Cada linha é um par de aeroportos dentro de um voo, e não um voo **por acaso**. As 214.882 linhas correspondem a **130.513 voos** (1,65 linha por voo): 68,4% dos voos têm uma linha, 24,6% têm três (desembarque, conexão internacional e conexão doméstica de uma empresa brasileira) e 10 voos chegam a 18 linhas. Contar linhas como se fossem voos superestima o número de voos em 65%. Por isso a pergunta de negócio é respondida na tabela por voo (notebook, seção 6.1), e não nas linhas.

A chave do grão (empresa, voo, data e hora, aeroportos, escala de destino e tipo de movimento) só se repete em **6 voos** **por acaso**, todos com partida no dia 1º do mês ou em 31/12. São o mesmo voo declarado em dois arquivos mensais (em 5 deles, as cópias divergem em ds_grupo_di). A cópia extra sai antes de qualquer soma.

5.2 Univariada numérica




Figura 3. Distribuição de nr_passag_pagos por linha. Notebook, seção 3.

A métrica principal, nr_passag_pagos, tem três modas **por acaso**: zero (31,4% das linhas), cerca de 150 (aviões de corredor único, rotas sul-americanas) e cerca de 270 (aviões de dois corredores, rotas longas). A média (107,9) e a mediana (114) ficam no vale entre as modas e não descrevem nenhum dos grupos: a leitura correta é por subpopulação.

As cinco medidas de peso são fortemente assimétricas (assimetria de 2,9 a 88,7) e têm de 66% a 97% de zeros. Para elas a mediana é zero e o resumo útil é a proporção de linhas com valor.

Outliers: erro, evento raro ou subpopulação

Variável	Candidatos (IQR)	O que são	Classificação
nr_passag_pagos	309 acima de 425	Emirates (302 linhas, até 484 pagos, Airbus A380) e Air France (7)	Subpopulação: manter
nr_passag_gratis	36.727 (Q3 = 1)	Máximo de 260 grátis com 9 pagos (Delta, 23/05/2025, destino Atlanta)	Evento raro ou erro de declaração: manter e reportar com e sem
kg_carga_paga	44.570 acima de 2.250	Cargueiros (até 126.977 kg)	Subpopulação: segmentar
kg_bagagem_livre	50.244 acima de 212	Voos longos de passageiros; os zeros são cargueiros e conexões	Subpopulação: segmentar

Variável	Candidatos (IQR)	O que são	Classificação
kg_carga_gratis	3 negativos (-3 a -33 kg)	Azul, out e nov/2025. Peso não pode ser negativo	Erro: vira nulo
kg_bagagem_excesso, kg_carga_gratis, kg_correio	IQR = 0	Mais de 95% de zeros: qualquer valor positivo vira outlier	Regra do IQR não se aplica

5.3 Univariada categórica

A base é concentrada. Guarulhos responde por 53,4% das linhas e 57,0% dos passageiros pagos; a LATAM Brasil (TAM), por 26,8% das linhas. A Argentina é o principal destino (26,2% das linhas), seguida de EUA (15,1%) e Chile (12,0%). O **recorte** tem 16,9% das linhas e **19,1% dos passageiros pagos** (4,4 de 23,2 milhões) [procurado](#); dentro dele, os EUA respondem por 83,2% dos passageiros, o Reino Unido por 11,1% e o Canadá por 5,7%. O que medimos é, na prática, o fluxo para os EUA.

Categorias raras: OUTRO ANGLÓFONO tem 1.448 linhas (África do Sul com 1.396; os outros 16 países, de 1 a 12 linhas cada); OCEANIA, uma linha; dois tipos de empresa têm 826 e 33 linhas.

5.4 Série temporal do recorte




Figura 4. Passageiros por mês em voos de passageiros para EUA, Canadá e Reino Unido. *Notebook*, seção 6.2.

O fluxo do recorte tem **pico em dezembro e janeiro** [procurado](#): 293,7 mil passageiros em jan/2025, 283,7 mil em dez/2025 e 296,9 mil em jan/2026, contra 213 a 237 mil nos demais meses, exceto março. Em índice: jan/2025 = 124, dez/2025 = 120, jan/2026 = 129. **Julho quase não se mexe**: 100 em 2025 e 102 em 2026. Há também um pico secundário em março nos dois anos, com índice 111 e 112 [por acaso](#).




Figura 5. Recorte: passageiros, voos e passageiros por voo, em índice (mar-jun do ano = 100). Notebook, seção 6.2.

O pico vem de **mais voos**, e não de voos mais cheios [procurado](#). Em jan/2025 os voos estão em 124 e os passageiros por voo em 100; em jan/2026, 128 e 101. Em dezembro, 115 e 104. As companhias aumentam a oferta para a alta temporada, e a ocupação média por voo pouco muda. O mesmo vale para o pico de março (voos em 116 e 112).

6. Análise multivariada

6.1 A relação mês → passageiros, controlada pelo grupo de destino procurado

Se o pico das férias fosse igual para o recorte e para os demais destinos, ele seria efeito das férias em geral, e a viagem a país de língua inglesa não traria informação própria. A faceta abaixo repete a mesma relação dentro de cada grupo de destino, com o mesmo eixo vertical.




Figura 6. Índice sazonal de passageiros por mês, por grupo de destino. Faixas cinza: meses de férias escolares. Notebook, seção 10.1.

Medida	Recorte	Não anglófono
Índice de jan/2025 (mar-jun = 100)	124,0	114,9
Índice de jan/2026	129,0	123,9
Índice de dez/2025	119,8	112,1
Julho sobre junho, 2025	+4,5%	+20,4%
Julho sobre junho, 2026	+8,4%	+28,6%

Resultado: o pico de dezembro e janeiro **sobrevive** ao controle e é mais forte no recorte. O pico de julho **não sobrevive**: aparece nos destinos não anglófonos (+20% e +29%) e quase some no recorte (+4,5% e +8,4%). Para a escola, as férias de julho não são uma época de viagem a país de língua inglesa acima do normal.

6.2 Dentro dos não anglófonos: de onde vem julho




Figura 7. Variação de passageiros de junho para julho por grupo e continente (2025 e 2026 somados). Notebook, seção 10.1.

Abrindo por continente, o aumento de julho se concentra na **América do Sul (+46%)**. Chile (43,2%) e Argentina (31,2%) explicam 74% do acréscimo de julho nos destinos não anglófonos **por acaso**. A Europa não anglófona sobe só 3,5%, e a

América do Norte não anglófona (quase toda México) sobe 29%.

A leitura candidata é turismo de inverno (neve no Chile e na Argentina) e de praia no México: viagens de férias que não envolvem inglês. É hipótese, não conclusão (seção 7).

6.3 Teste de Simpson na combinação escolhida pelo grupo procurado

O teste automático do notebook escolheu `ds_cotran` × `ds_tipo_empresa` e acusou inversão num segmento de 33 linhas. A combinação não tem sentido de negócio e o segmento é pequeno demais. A combinação escolhida pelo grupo responde a uma pergunta do domínio: **nas férias escolares (jan, jul, dez) os voos saem mais cheios, e isso vale dentro de cada grupo de destino?** Base: 74.464 voos de passageiros de 2025, um ano civil completo. Métrica: passageiros por voo.

Segmento	Voos nas férias	Voos fora	Pax/voo nas férias	Pax/voo fora	Diferença	IC 95% (bootstrap)
Agregado	20.434	54.030	192,3	194,2	-1,9	-3,2 a -0,5
Recorte	3.240	8.412	251,5	246,3	+5,2	+2,1 a +8,6
Não anglófono	17.078	45.311	180,9	184,4	-3,5	-5,0 a -2,1
Outro anglófono	116	307	226,6	213,8	+12,7	+0,3 a +25,3

Resultado: inversão parcial. No agregado, voo de férias leva 1,9 passageiro a menos. No recorte (e nos outros anglófonos), leva mais; só os não anglófonos seguem o agregado. Em 2025 os intervalos de confiança não cruzam o zero, mas as diferenças são pequenas (cerca de 2% do passageiro por voo).

Não é paradoxo de Simpson por composição. A participação do recorte quase não muda entre os períodos (15,6% dos voos fora das férias, 15,9% nas férias). O que acontece é um efeito com sinais opostos nos segmentos, que o agregado esconde porque os não anglófonos são 84% dos voos. A lição é a mesma: reportar só o agregado levaria à conclusão errada para o recorte. Repetindo o teste por continente, a inversão aparece em 3 de 6 segmentos (América do Norte, América Central e África ficam mais cheias nas férias; América do Sul, Europa e Ásia, não).

Verificação num recorte não usado. O teste foi feito com 2025. Repetido em jan-jul/2026 (férias = janeiro e julho), que não entrou na escolha da combinação:

Segmento	Voos nas férias	Voos fora	Diferença (pax/voo)	IC 95% (bootstrap)
Agregado	14.883	31.050	-6,2	-7,8 a -4,6
Recorte	2.091	4.546	+1,4	-3,2 a +5,9
Não anglófono	12.702	26.316	-7,2	-8,8 a -5,6

Os não anglófonos repetem o resultado. O recorte mantém a direção, mas o intervalo passa a incluir o zero: **a inversão no recorte não se confirma** e fica registrada como hipótese, não como achado.

Ressalva: o bootstrap trata os voos como independentes. Voos da mesma rota e companhia são parecidos entre si, então os intervalos reais são mais largos que os mostrados.

6.4 Variáveis de confusão que não estão na base

Câmbio (dólar e libra), preço da passagem, política de vistos e **assentos ofertados** podem explicar tanto o volume quanto a sazonalidade, e nenhum deles está na base combinada. Sem assentos não há taxa de ocupação, que é a medida que separaria "mais gente quer viajar" de "as companhias puseram mais aviões". Isso vai para as limitações.

7. Síntese

Achados

	Afirmção sobre o dado	Medida	Sustentação
procurado	O recorte é cerca de um quinto do fluxo internacional, e é quase todo EUA	19,1% dos passageiros pagos; EUA 83,2% do recorte	Seção 5.3; notebook, seção 9
procurado	O pico do recorte é dezembro e janeiro	Índices 124 (jan/25), 120 (dez/25), 129 (jan/26)	Figura 4
procurado	O pico de julho não sobrevive ao controle pelo grupo de destino	Jul/jun: recorte +4,5% e +8,4%; não anglófono +20,4% e +28,6%	Figura 6
procurado	O pico do recorte vem de mais voos, não de voos mais cheios	Jan/26: voos 128, pax/voo 101	Figura 5
procurado	O agregado de passageiros por voo nas férias esconde segmentos com sinais opostos; no recorte o sinal positivo de 2025 não se confirmou em 2026	2025: recorte +5,2 (IC 2,1 a 8,6), agregado -1,9; 2026: recorte +1,4 (IC -3,2 a 5,9)	Seção 6.3
por acaso	A ausência de ds_cotran é determinada pela nacionalidade da empresa	100% nulo nas estrangeiras, 0% nas brasileiras	Figura 1
por acaso	Seis voos estão duplicados na virada do mês	6 repetições da chave, todas no dia 1º ou 31/12	Seção 5.1
por acaso	Julho dos não anglófonos é concentrado em Chile e Argentina	74% do acréscimo; América do Sul +46%	Figura 7
por acaso	O recorte tem um segundo pico em março	Índices 111 e 112; voos 116 e 112	Figuras 4 e 5
por acaso	Passageiros por linha têm três modas	31,4% zero; modas perto de 150 e 270	Figura 3

Hipóteses

Achado	Explicação candidata	O que seria necessário para verificar
Pico de dez/jan	Férias de fim de ano e viagens de lazer e compras aos EUA	Motivo da viagem (pesquisas da Embratur, dados da Polícia Federal); para o projeto, a data de cadastro dos alunos do cliente, testando defasagens de 1 a 6 meses
Julho fora do recorte	Turismo de inverno na América do Sul e de praia no México e no Caribe	Abrir por cidade (Santiago, Bariloche, Mendoza, Cancún) e repetir com mais anos
Pico de março	Aumento de oferta das companhias (feriados de Páscoa, primavera no hemisfério norte)	Malha programada (HOTRAN) e anos anteriores a 2025
Mais cheio nas férias só no recorte	Recorte usa aviões grandes com oferta pouco flexível, que encham; os não anglófonos ganham frequências extras e o passageiro por voo cai. A parte do recorte não se repetiu em 2026	Assentos ofertados por voo (base de etapas básicas da ANAC) para calcular ocupação, e mais anos de dados
ds_cotran nulo	Estrangeiras declaram em formato sem tipo de movimento	Dicionário oficial da base combinada da ANAC
68 linhas sem medida	Declarações incompletas ainda não revisadas (26 em mai-jul/2026)	Baixar de novo os mesmos meses após a revisão da ANAC
Duplicatas na virada do mês	Voo na fronteira entre dois arquivos mensais entra nos dois	Comparar com nr_ano_mes_referencia, que existe na base bruta

Decisões de tratamento

Tema	Decisão	Justificativa
Ausentes: ds_cotran	Não imputar; recodificar como NÃO DETALHADO; análise por tipo de movimento só com empresas brasileiras	O valor não existe na origem (ausência estrutural); imputar inventaria um dado
Ausentes: NÃO IDENTIFICADO	Manter como categoria, fora de NA_EXTRA	Marca o regime de declaração das estrangeiras; transformar em nulo esconderia essa informação
Ausentes: 68 linhas sem medida	Remover, com o motivo registrado	Sem nenhuma medida, não entram em métrica alguma; são 0,03% da base
Duplicatas	Manter uma cópia dos 6 voos repetidos	O mesmo voo contado duas vezes infla passageiros e voos
Outlier: kg_carga_gratis negativo	Transformar em nulo	Erro: peso não pode ser negativo
Outlier: 260 passageiros grátis	Manter; reportar métricas de grátis com e sem	Pode ser evento real (voo de cortesia, fretamento); não afeta a métrica principal (pagos)
Outlier: Emirates 484 pagos	Manter	Subpopulação legítima (A380), não erro
Zeros de passageiros	Segmentar: unidade de análise passa a ser o voo, cargueiros e improdutivos saem da métrica de demanda	São subpopulações (carga, conexão doméstica, traslado), não ausência
Registro das decisões	Criar as flags sem_medida, duplicata_virada_mes e peso_negativo na base tratada	Guarda a decisão como variável, em vez de escondê-la; quem usar a base depois consegue reproduzir ou desfazer
Categorias raras	OUTRO ANGLÓFONO separado (fora do recorte e do controle); OCEANIA em Outros; tipos de empresa raros agrupados em brasileira/estrangeira; meses residuais (dez/24, ago/26) fora das séries	Segmentos com n baixo oscilam por construção e não sustentam comparação

Limitações

- 1. A base mede voos, não pessoas.** Não tem nacionalidade (um americano voltando para casa conta como saída do Brasil para os EUA), motivo da viagem nem destino final. Irlanda, Austrália e Nova Zelândia não aparecem, porque se chega a elas por conexão. Logo, a base não permite afirmar quantos brasileiros viajaram a país de língua inglesa, nem por quê.
- 2. Não há dado de demanda por aulas.** A pergunta P4 (a matrícula antecede a viagem?) depende da base do cliente, que guarda a data completa de cadastro. Esta EDA descreve só o lado das viagens.
- 3. 19 meses dão um ciclo anual completo.** Janeiro a julho têm duas observações; agosto a dezembro, uma. A base não separa tendência de sazonalidade com segurança, e o pico de março pode ser de um biênio específico.
- 4. Variáveis de confusão fora da base:** câmbio, preço da passagem, política de vistos e assentos ofertados. Sem assentos não há taxa de ocupação, e o teste da seção 6.3 não distingue demanda de oferta.
- 5. 68,1% dos passageiros pagos** (empresas estrangeiras) não podem ser separados entre desembarque e conexão.